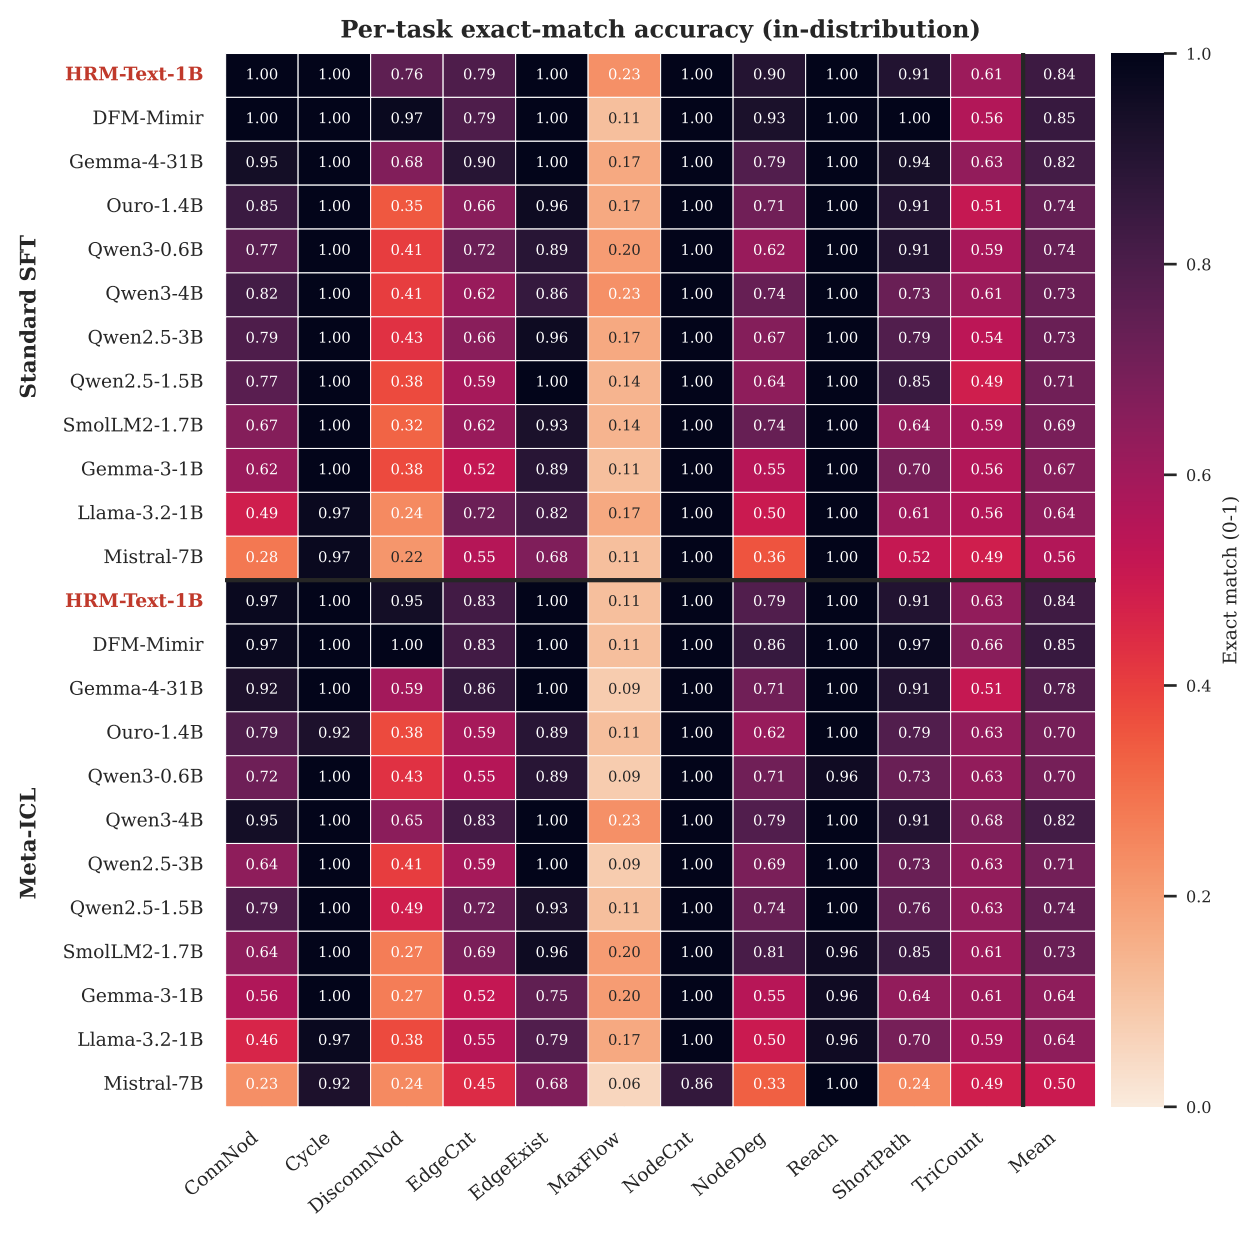
Per-task exact-match accuracy (in-distribution)
Standard SFT
Meta-ICL
HRM-Text-1B 1.00 1.00 0.76 0.79 1.00 0.23 1.00 0.90 1.00 0.91 0.61 0.84
DFM-Mimir 1.00 1.00 0.97 0.79 1.00 0.11 1.00 0.93 1.00 1.00 0.56 0.85
Gemma-4-31B 0.95 1.00 0.68 0.90 1.00 0.17 1.00 0.79 1.00 0.94 0.63 0.82
Ouro-1.4B 0.85 1.00 0.35 0.66 0.96 0.17 1.00 0.71 1.00 0.91 0.51 0.74
Qwen3-0.6B 0.77 1.00 0.41 0.72 0.89 0.20 1.00 0.62 1.00 0.91 0.59 0.74
Qwen3-4B 0.82 1.00 0.41 0.62 0.86 0.23 1.00 0.74 1.00 0.73 0.61 0.73
Qwen2.5-3B 0.79 1.00 0.43 0.66 0.96 0.17 1.00 0.67 1.00 0.79 0.54 0.73
Qwen2.5-1.5B 0.77 1.00 0.38 0.59 1.00 0.14 1.00 0.64 1.00 0.85 0.49 0.71
SmolLM2-1.7B 0.67 1.00 0.32 0.62 0.93 0.14 1.00 0.74 1.00 0.64 0.59 0.69
Gemma-3-1B 0.62 1.00 0.38 0.52 0.89 0.11 1.00 0.55 1.00 0.70 0.56 0.67
Llama-3.2-1B 0.49 0.97 0.24 0.72 0.82 0.17 1.00 0.50 1.00 0.61 0.56 0.64
Mistral-7B 0.28 0.97 0.22 0.55 0.68 0.11 1.00 0.36 1.00 0.52 0.49 0.56
HRM-Text-1B 0.97 1.00 0.95 0.83 1.00 0.11 1.00 0.79 1.00 0.91 0.63 0.84
DFM-Mimir 0.97 1.00 1.00 0.83 1.00 0.11 1.00 0.86 1.00 0.97 0.66 0.85
Gemma-4-31B 0.92 1.00 0.59 0.86 1.00 0.09 1.00 0.71 1.00 0.91 0.51 0.78
Ouro-1.4B 0.79 0.92 0.38 0.59 0.89 0.11 1.00 0.62 1.00 0.79 0.63 0.70
Qwen3-0.6B 0.72 1.00 0.43 0.55 0.89 0.09 1.00 0.71 0.96 0.73 0.63 0.70
Qwen3-4B 0.95 1.00 0.65 0.83 1.00 0.23 1.00 0.79 1.00 0.91 0.68 0.82
Qwen2.5-3B 0.64 1.00 0.41 0.59 1.00 0.09 1.00 0.69 1.00 0.73 0.63 0.71
Qwen2.5-1.5B 0.79 1.00 0.49 0.72 0.93 0.11 1.00 0.74 1.00 0.76 0.63 0.74
SmolLM2-1.7B 0.64 1.00 0.27 0.69 0.96 0.20 1.00 0.81 0.96 0.85 0.61 0.73
Gemma-3-1B 0.56 1.00 0.27 0.52 0.75 0.20 1.00 0.55 0.96 0.64 0.61 0.64
Llama-3.2-1B 0.46 0.97 0.38 0.55 0.79 0.17 1.00 0.50 0.96 0.70 0.59 0.64
Mistral-7B 0.23 0.92 0.24 0.45 0.68 0.06 0.86 0.33 1.00 0.24 0.49 0.50
ConnNod
Cycle
DisconnNod
EdgeCnt
EdgeExist
MaxFlow
NodeCnt
NodeDeg
Reach
ShortPath
TriCount
Mean
Exact match (0-1)
1.0
0.8
0.6
0.4
0.2
0.0