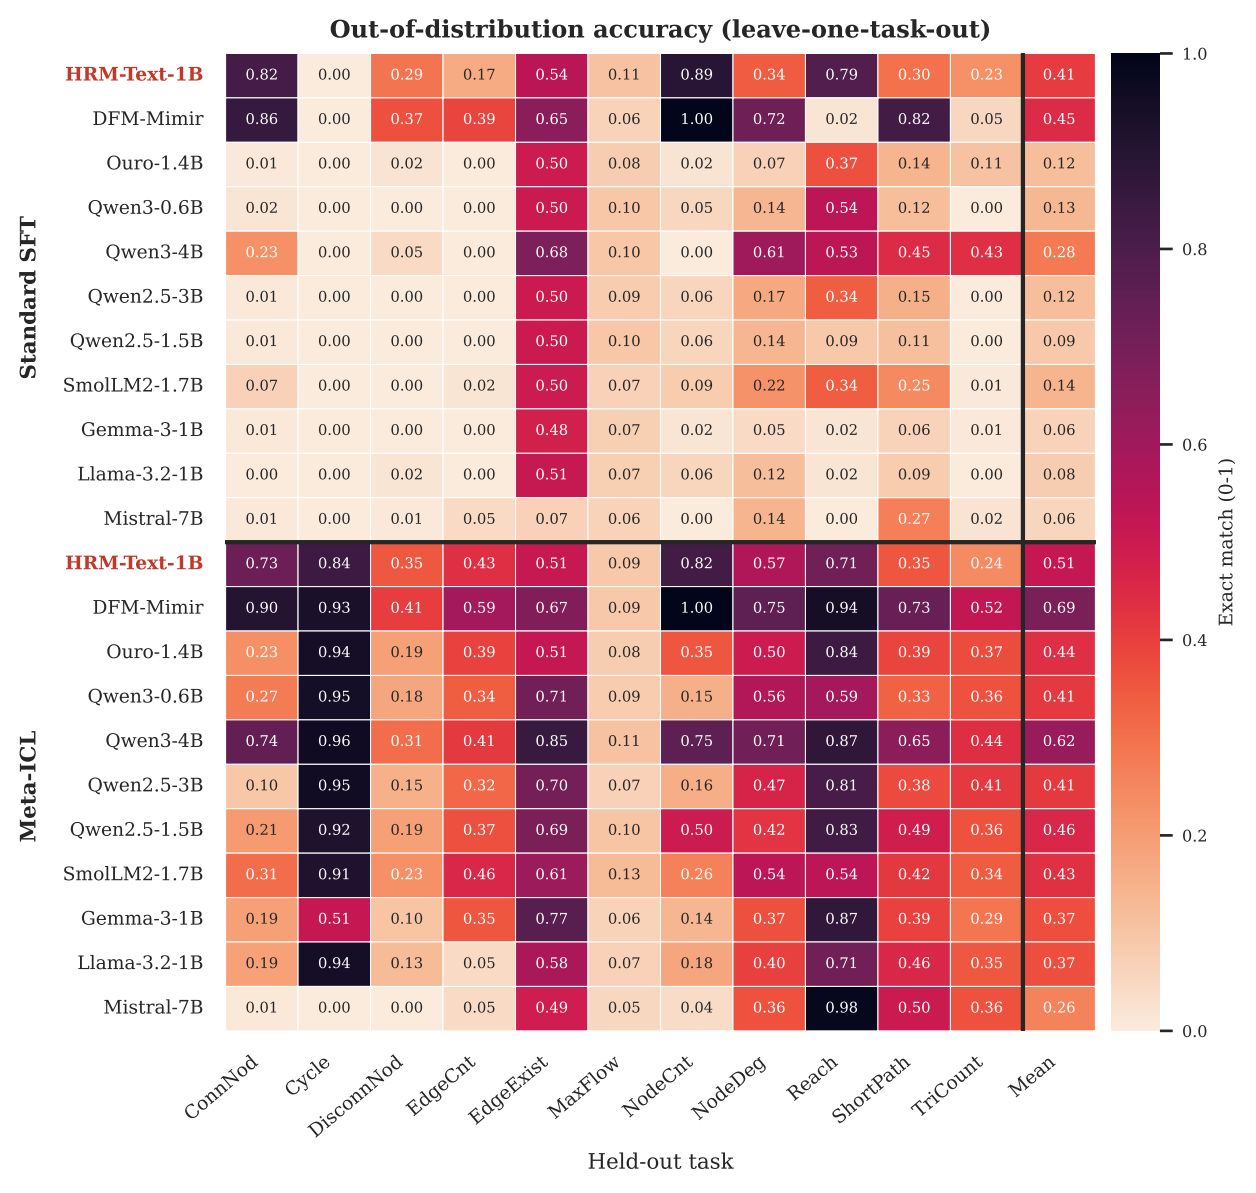
Out-of-distribution accuracy (leave-one-task-out)
Standard SFT
Meta-ICL
HRM-Text-1B 0.82 0.00 0.29 0.17 0.54 0.11 0.89 0.34 0.79 0.30 0.23 0.41
DFM-Mimir 0.86 0.00 0.37 0.39 0.65 0.06 1.00 0.72 0.02 0.82 0.05 0.45
Ouro-1.4B 0.01 0.00 0.02 0.00 0.50 0.08 0.02 0.07 0.37 0.14 0.11 0.12
Qwen3-0.6B 0.02 0.00 0.00 0.00 0.50 0.10 0.05 0.14 0.54 0.12 0.00 0.13
Qwen3-4B 0.23 0.00 0.05 0.00 0.68 0.10 0.00 0.61 0.53 0.45 0.43 0.28
Qwen2.5-3B 0.01 0.00 0.00 0.00 0.50 0.09 0.06 0.17 0.34 0.15 0.00 0.12
Qwen2.5-1.5B 0.01 0.00 0.00 0.00 0.50 0.10 0.06 0.14 0.09 0.11 0.00 0.09
SmolLM2-1.7B 0.07 0.00 0.00 0.02 0.50 0.07 0.09 0.22 0.34 0.25 0.01 0.14
Gemma-3-1B 0.01 0.00 0.00 0.00 0.48 0.07 0.02 0.05 0.02 0.06 0.01 0.06
Llama-3.2-1B 0.00 0.00 0.02 0.00 0.51 0.07 0.06 0.12 0.02 0.09 0.00 0.08
Mistral-7B 0.01 0.00 0.01 0.05 0.07 0.06 0.00 0.14 0.00 0.27 0.02 0.06
HRM-Text-1B 0.73 0.84 0.35 0.43 0.51 0.09 0.82 0.57 0.71 0.35 0.24 0.51
DFM-Mimir 0.90 0.93 0.41 0.59 0.67 0.09 1.00 0.75 0.94 0.73 0.52 0.69
Ouro-1.4B 0.23 0.94 0.19 0.39 0.51 0.08 0.35 0.50 0.84 0.39 0.37 0.44
Qwen3-0.6B 0.27 0.95 0.18 0.34 0.71 0.09 0.15 0.56 0.59 0.33 0.36 0.41
Qwen3-4B 0.74 0.96 0.31 0.41 0.85 0.11 0.75 0.71 0.87 0.65 0.44 0.62
Qwen2.5-3B 0.10 0.95 0.15 0.32 0.70 0.07 0.16 0.47 0.81 0.38 0.41 0.41
Qwen2.5-1.5B 0.21 0.92 0.19 0.37 0.69 0.10 0.50 0.42 0.83 0.49 0.36 0.46
SmolLM2-1.7B 0.31 0.91 0.23 0.46 0.61 0.13 0.26 0.54 0.54 0.42 0.34 0.43
Gemma-3-1B 0.19 0.51 0.10 0.35 0.77 0.06 0.14 0.37 0.87 0.39 0.29 0.37
Llama-3.2-1B 0.19 0.94 0.13 0.05 0.58 0.07 0.18 0.40 0.71 0.46 0.35 0.37
Mistral-7B 0.01 0.00 0.00 0.05 0.49 0.05 0.04 0.36 0.98 0.50 0.36 0.26
ConnNod
Cycle
DisconnNod
EdgeCnt
EdgeExist
MaxFlow
NodeCnt
NodeDeg
Reach
ShortPath
TriCount
Mean
Held-out task
Exact match (0-1)
1.0
0.8
0.6
0.4
0.2
0.0